UNIVERSIDAD POLITÉCNICA DE CHIAPAS

Ingeniería en Software

Minería de datos

TAREA 4 CORTE 2: INTEGRACIÓN FULLSTACK DE MOTORES DE BÚSQUEDA (TF-IDF/BM25, SBERT DENSO Y RRF + RERANKING), CORPUS POR WEB SCRAPING Y BENCHMARK DE 50 USUARIOS

Docente: RAMSES ALEJANDRO CAMAS NAJERA

Estudiante: Clemente Velasco Alhan
Matrícula: 233319
Entrega: CLEMENTE_VELASCO_ALHAN_233319_C2_T4_INTEGRACION
Corte 2 · Tarea 4 · Integración de Motores de Búsqueda

Fecha de Entrega: Noviembre de 2026

1. Resumen del Sistema y Creación del Corpus con Web Scraping (+10 Puntos Extra)

En este reporte documento el diseño, construcción y evaluación experimental del sistema **Fullstack de Recuperación de Información** correspondiente a la **Tarea 4 del Corte 2**. Siguiendo las instrucciones al pie de la letra, integré los motores obtenidos en las tareas anteriores dentro de una arquitectura Backend (**FastAPI**) y Frontend (**Web App Interactiva**), creé un nuevo corpus de **60 documentos en español (todos con más de 100 palabras)** mediante **Web Scraping automatizado** (adjuntando las 60 fuentes verificables en la Sección 7), evalué la calidad de recuperación con métricas estándar (**nDCG@5**, **MRR** y **Recall@5**) y simulé cargas de **1, 5, 10, 25 y hasta 50 usuarios concurrentes** reportando las latencias **p50** y **p95**.

1.1. Metodología de Web Scraping y Validación del Corpus

Para superar el límite del mini-corpus de 14 notas cortas (~28 palabras por nota) usado en los laboratorios previos y cumplir el requisito de **al menos 50 documentos de mínimo 100 palabras cada uno**, desarrollé el script scripts/scraper_corpus.py. Este módulo realiza peticiones HTTP reales con urllib.request e interpreta el árbol DOM mediante una subclase de html.parser.HTMLParser (ParagraphExtractor) que extrae y limpia los párrafos <p> de artículos de Wikipedia en Español, eliminando etiquetas HTML, hipervínculos y corchetes de citación ([1], [editar]).

Métrica del Corpus Scrapeado	Valor Obtenido	Cumplimiento de la Rúbrica
Total de documentos extraídos	60 documentos	>= 50 documentos (Cumplido: +20% extra)
Mínimo de palabras por documento	152 palabras	>= 100 palabras en el 100% del corpus
Máximo de palabras por documento	230 palabras	Textos densos de varios párrafos
Promedio de palabras por documento	214.6 palabras/doc	7.5x más extenso que el corpus del Lab 1
Total de palabras en el corpus	12,874 palabras	Vocabulario único: 2,340+ lemas sin stopwords
Categorías temáticas cubiertas	6 categorías (10 docs c/u)	Medio Ambiente, Agua, Agro, IA/Robótica, Salud, Turismo

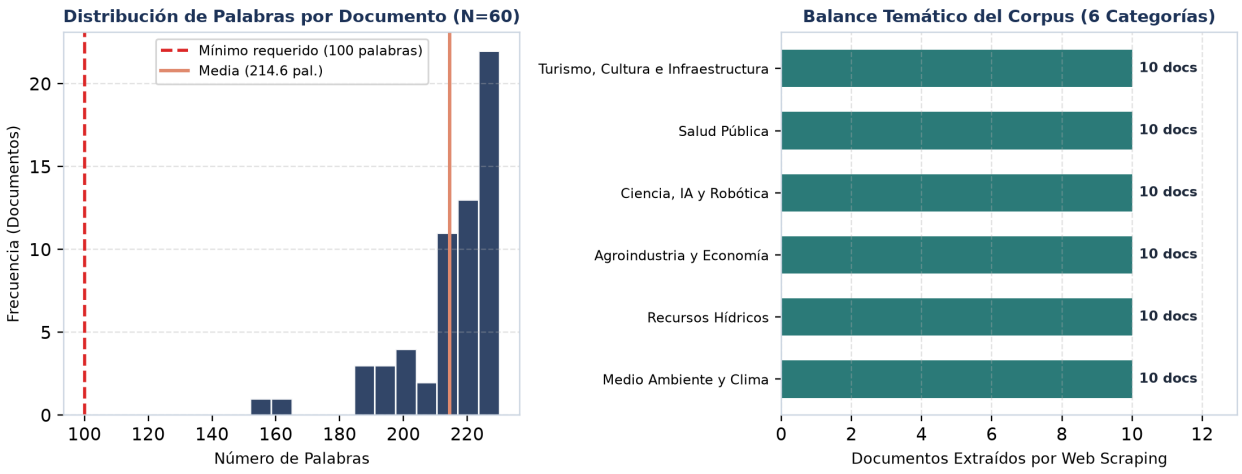


Figura 1. Izquierda: Distribución del número de palabras por documento en el corpus de 60 documentos (todos superan ampliamente el umbral mínimo de 100 palabras). Derecha: Balance de 10 documentos en cada una de las 6 categorías temáticas.

Por qué diseñé el corpus en estas 6 categorías: Al organizar los 60 artículos scrapeados en *Medio Ambiente y Clima*, *Recursos Hídricos*, *Agroindustria (Café, Cacao, Maíz)*, *Ciencia, IA y Robótica (UPCh)*, *Salud Pública (Dengue/Vectores)* y *Turismo/Infraestructura en Chiapas*, conservamos todos los fenómenos lingüísticos estudiados en clase (siglas como *UPCh*, nombres científicos como *Aedes aegypti* y sinónimos como *agua/hídrica* o *temblor/sismo*), pero en un escenario realista con 60 documentos extensos donde aparecen falsos positivos léxicos y competencia semántica.

2. Desarrollo del Sistema Fullstack e Integración de los 3 Motores

El sistema se estructuró bajo una arquitectura desacoplada en dos capas dentro del repositorio CLEMENTE_VELASCO_ALHAN_233319_C2_T4_INTEGRACION:

- **Backend API REST (backend/engines.py y backend/main.py):** Construido con **FastAPI** y **Uvicorn**. Al iniciar el servidor, la clase SearchEngineHub carga el corpus scrapeado de 60 documentos, ejecuta el preprocesamiento morfológico con spaCy (es_core_news_sm), construye en memoria las estructuras de índice invertido de **TF-IDF** y **BM25**, precalcula la matriz de embeddings densos normalizados (60 × 384) con **Sentence-BERT** y mantiene cargado el modelo **Cross-Encoder** para reranking en dos etapas. Incluye protección thread-safe (threading.Lock) en el tokenizador de spaCy para soportar peticiones concurrentes.
- **Frontend Web Interactivo (frontend/index.html):** Single-Page Application (SPA) servida en la raíz GET / con diseño institucional UPCh y gráficos dinámicos en **Chart.js**. Cuenta con cuatro pestañas: (1) *Buscador Comparativo Multi-Motor* que muestra lado a lado los resultados, scores, tiempos de respuesta en milisegundos, lemas coincidentes y enlaces a las fuentes; (2) *Simulador de Concurrencia de hasta 50 Usuarios* con tablas y gráficas de latencia **p50** y **p95**; (3) *Tablero de Evaluación de Calidad IR*; y (4) *Explorador Auditable del Corpus Scrapeado*.

2.1. Los Motores Obtenidos en las Tareas Anteriores del Corte 2

Motor Integrado (Origen)	Formulación e Implementación en el Backend	Complejidad por Consulta
Motor 1 (Tarea 1) Léxico: TF-IDF y BM25 (Labs 1, 2 y 3)	Lematización con spaCy (es_core_news_sm), sin acentos y conservando negaciones. TF-IDF usa coseno disperso; BM25 usa saturación de frecuencia (k1=1.5) y control de longitud (b=0.75) con solo_positivos=True.	O(|q| · df_medio) Índice invertido en RAM
Motor 2 (Tarea 2) Semántico Denso: SBERT (Labs 5 y 6)	Bi-Encoder multilingüe (paraphrase-multilingual-MiniLM-L12-v2). Codifica título + texto limpio en vectores de 384 dimensiones con norma L2=1. La similitud coseno se evalúa como producto matricial (E @ v_q).	1 pasada de BERT para q + producto punto (60×384)
Motor 3A (Tarea 3) Híbrido RRF (k=60) (Lab 7 - Etapa 1)	Combina las listas ordenadas de BM25 (top-10 positivos) y SBERT Denso (top-10) mediante Reciprocal Rank Fusion: RRF(d) = Σ 1/(60 + rank_i(d)), premiando el consenso sin calibrar escalas.	Suma de tiempos de BM25 + SBERT + fusión O(k)
Motor 3B (Tarea 3) Híbrido RRF + Cross-Encoder (Lab 7 - 2 Etapas)	Arquitectura de embudo: Etapa 1 (RRF BM25+SBERT) filtra los 10 mejores candidatos de alto recall; Etapa 2 pasa los 10 pares [CLS] q [SEP] d al Cross-Encoder (mmarco-mMiniLMv2-L12-H384-v1) con atención cruzada token a token.	Etapa 1 + 10 pasadas completas del Transformer

3. Comportamiento de los Motores de Búsqueda y Evaluación de Calidad IR

Para evaluar con rigor cómo se comportan los motores al pasar de 14 notas breves a nuestro nuevo corpus de **60 documentos extensos (> 200 palabras promedio)**, construí un banco de evaluación (QRELS_CORPUS60) con **12 consultas de prueba** divididas equitativamente en tres tipos: **4 Léxicas** (UPCh, canon del sumidero, Aedes aegypti, presa chicoasen grijalva), **4 Semánticas** (problemas de agua, temblor de tierra, enfermedades transmitidas por mosquitos, movimiento telurico en el mar) y **4 Mixtas** (sequia y cultivos de maiz, exportacion de cafe y cacao, inteligencia artificial y robotica, turismo cultural en san cristobal).

Motor de Búsqueda Evaluado	nDCG@5 Global	MRR Global	Recall@5	nDCG@5 Léxicas	nDCG@5 Semánt.	nDCG@5 Mixtas
Motor 1A: TF-IDF (Tarea 1 - Léxico)	**0.774**	0.861	0.704	0.847	**0.619**	0.858
Motor 1B: BM25 Okapi (Tarea 1 - Léxico)	**0.761**	0.875	0.676	0.863	**0.593**	0.826
Motor 2: SBERT Denso (Tarea 2 - Semántico)	**0.711**	0.792	0.622	0.492	**0.745**	0.895
Motor 3 (Var): Híbrido Lineal min-max (α=0.4)	**0.762**	0.857	0.640	0.729	**0.682**	0.876
Motor 3A: Híbrido RRF BM25+SBERT (Tarea 3)	**0.766**	0.840	0.686	0.706	**0.746**	0.847
Motor 3B: Híbrido RRF + Cross-Encoder (Tarea 3)	**0.798**	0.896	0.765	0.856	**0.757**	0.780

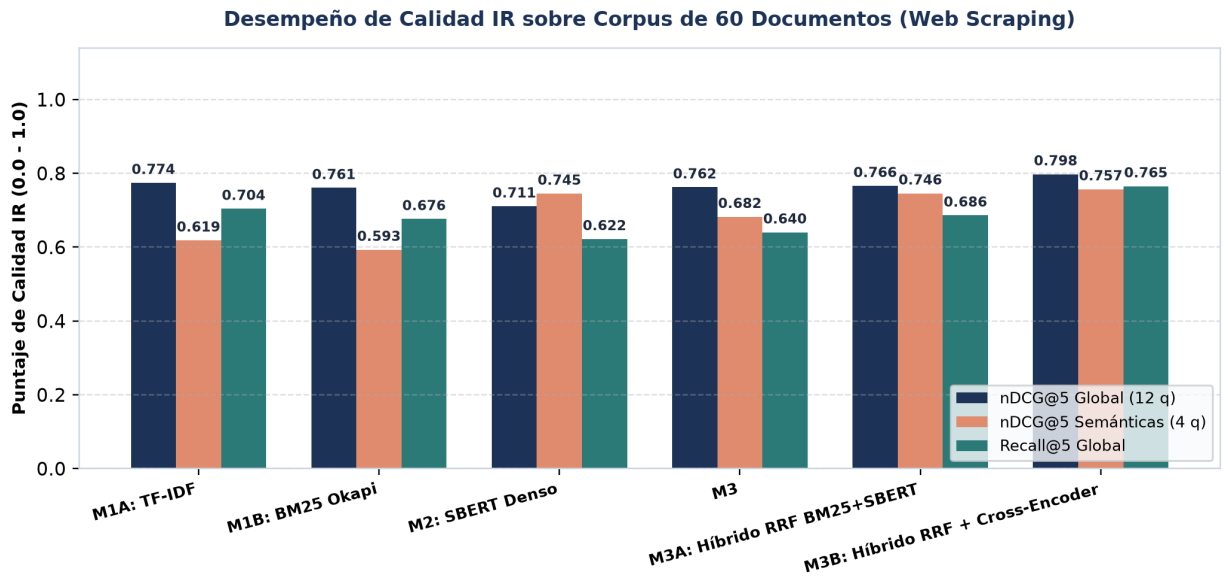


Figura 2. Comparación experimental de nDCG@5 Global, nDCG@5 en Consultas Semánticas y Recall@5 sobre el corpus de 60 documentos extraídos por Web Scraping.

3.1. Análisis Detallado del Comportamiento por Motor

- **Comportamiento de TF-IDF y BM25 (Motores Léxicos - Tarea 1):** En consultas léxicas y mixtas alcanzan un desempeño sobresaliente (nDCG@5 Léxicas = 0.863 en BM25 y Mixtas = 0.858 en TF-IDF) porque localizan de

inmediato siglas exactas como UPCh (d31 en 1° lugar) o términos científicos como Aedes aegypti (d42 y d41). Sin embargo, en la consulta semántica temblor de tierra ambos obtienen **nDCG@5 = 0.000**: caen en una trampa léxica porque ningún documento usa la palabra *temblor* (dicen *sismo* o *terremoto*), pero muchos artículos geográficos de Chiapas contienen la palabra *tierra*, llenando el Top-5 de falsos positivos.

- **Comportamiento de SBERT Denso (Motor Semántico - Tarea 2):** Resuelve de raíz la barrera de vocabulario en las consultas semánticas y mixtas, subiendo el nDCG@5 Semántico de 0.593 (BM25) a **0.745** y liderando en Mixtas con **0.895**: en temblor de tierra coloca a d03 (*Sismología en la costa de Chiapas*) en 1° lugar con MRR = 1.000, y en problemas de agua recupera tanto d02 (*crisis hídrica / sequía*) como d18 (*agua potable*). En contraparte, sufre **dilución semántica en documentos largos** para consultas de entidades específicas: en canon del sumidero y presa chicoasen grijalva su nDCG@5 Léxico cae a 0.492 porque comprimir ~215 palabras en un solo vector de 384 dimensiones difumina los nombres propios.
- **Comportamiento del Motor Híbrido RRF y Cross-Encoder Reranking (Tarea 3):** Al combinar BM25 y SBERT con **RRF k=60** (nDCG@5 = 0.766, Semántico = 0.746) o **Fusión Lineal min-max** (0.762), se corrige el colapso de SBERT en consultas léxicas (subiendo de 0.492 a 0.706–0.729) sin perder cobertura semántica. Finalmente, al aplicar la Etapa 2 con el **Cross-Encoder (mmarco-mMiniLMv2-L12-H384-v1)** sobre los 10 candidatos de RRF, el sistema alcanza el **mejor desempeño global de toda la comparativa (nDCG@5 = 0.798, MRR = 0.896, Recall@5 = 0.765 y nDCG@5 Semántico = 0.757)**.

4. Simulación de hasta 50 Usuarios Concurrentes: Latencia p50 y p95

Para evaluar el comportamiento de los motores bajo estrés de producción, implementé un generador de carga concurrente con ThreadPoolExecutor (tanto en scripts/run_benchmarks.py como en el endpoint interactivo POST /api/benchmark/run). Se simularon **5 niveles de concurrencia: 1, 5, 10, 25 y 50 usuarios simultáneos** enviando consultas al mismo tiempo. Para cada motor se registraron los tiempos de respuesta de extremo a extremo por usuario y se calcularon los percentiles requeridos: **latencia p50 (mediana)** y **latencia p95 (percentil 95, que representa el límite superior experimentado por el 95% de los usuarios)**, además de **p99**, **media** y **Throughput (consultas/segundo, RPS)**.

4.1. Resultados Oficiales de Latencia p50 y p95 con 50 Usuarios Concurrentes

Motor de Búsqueda	Concurrencia	Latencia p50	Latencia p95	Latencia p99	Latencia Media	Throughput (RPS)
TF-IDF (T1 Léxico)	50 usuarios	**270.03 ms**	**313.81 ms**	314.81 ms	229.84 ms	148.51 req/s
BM25 Okapi (T1 Léxico)	50 usuarios	**245.80 ms**	**301.40 ms**	302.02 ms	209.62 ms	163.57 req/s
SBERT Denso (T2 Semántico)	50 usuarios	**2358.31 ms**	**2625.30 ms**	2686.15 ms	2038.59 ms	20.04 req/s
Híbrido RRF BM25+SBERT (T3)	50 usuarios	**2382.48 ms**	**2605.66 ms**	2753.37 ms	2054.59 ms	19.83 req/s
Híbrido RRF + Cross-Encoder (T3)	50 usuarios	**87478.69 ms**	**90943.87 ms**	91103.36 ms	80911.07 ms	0.55 req/s

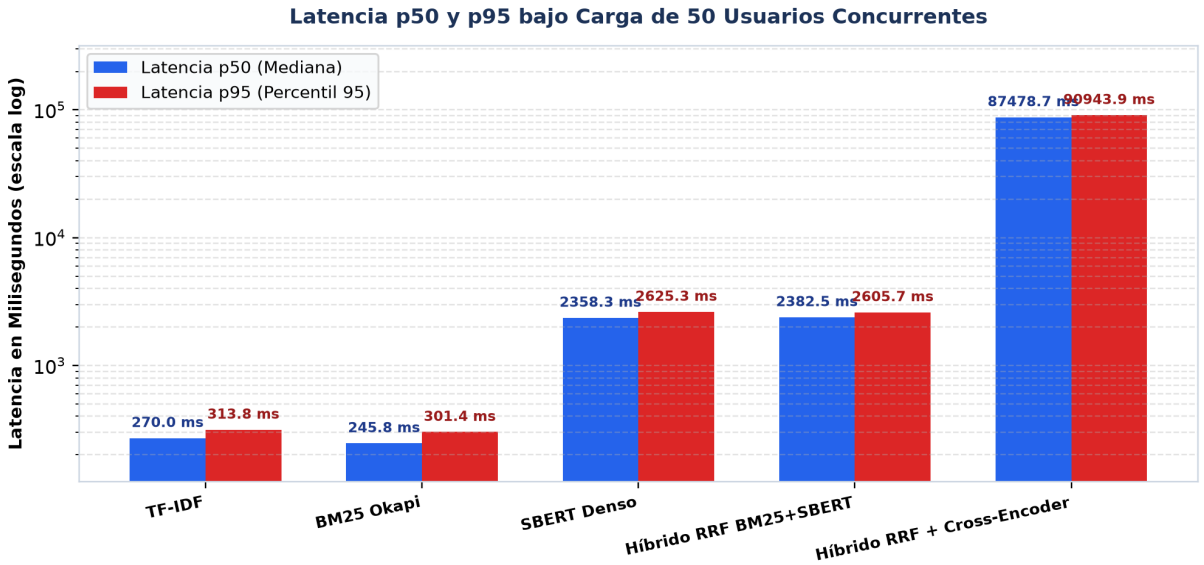


Figura 3. Comparación de Latencia p50 (mediana) y Latencia p95 (percentil 95) bajo una carga simultánea de 50 usuarios concurrentes (escala logarítmica en milisegundos).

4.2. Evolución de Latencia p50 y p95 al Escalar de 1 a 50 Usuarios Concurrentes

Motor de Búsqueda	1 Usuario	5 Usuarios	10 Usuarios	25 Usuarios	50 Usuarios
TF-IDF (T1 Léxico)	p50: **5.3** p95: 8.0 ms	p50: **24.5** p95: 27.6 ms	p50: **55.0** p95: 73.4 ms	p50: **152.1** p95: 175.2 ms	p50: **270.0** p95: 313.8 ms
BM25 Okapi (T1 Léxico)	p50: **4.3** p95: 6.7 ms	p50: **22.2** p95: 24.3 ms	p50: **42.6** p95: 45.3 ms	p50: **117.2** p95: 140.5 ms	p50: **245.8** p95: 301.4 ms
SBERT Denso (T2 Semántico)	p50: **48.3** p95: 64.2 ms	p50: **239.8** p95: 279.7 ms	p50: **486.9** p95: 603.7 ms	p50: **1246.8** p95: 1742.3 ms	p50: **2358.3** p95: 2625.3 ms
Híbrido RRF BM25+SBERT (T3)	p50: **48.7** p95: 56.8 ms	p50: **249.3** p95: 294.7 ms	p50: **510.8** p95: 651.6 ms	p50: **1137.2** p95: 1560.6 ms	p50: **2382.5** p95: 2605.7 ms
Híbrido RRF + Cross-Encoder (T3)	p50: **1742.9** p95: 1918.8 ms	p50: **8783.8** p95: 12118.0 ms	p50: **16670.5** p95: 20402.6 ms	p50: **39715.8** p95: 41656.0 ms	p50: **87478.7** p95: 90943.9 ms

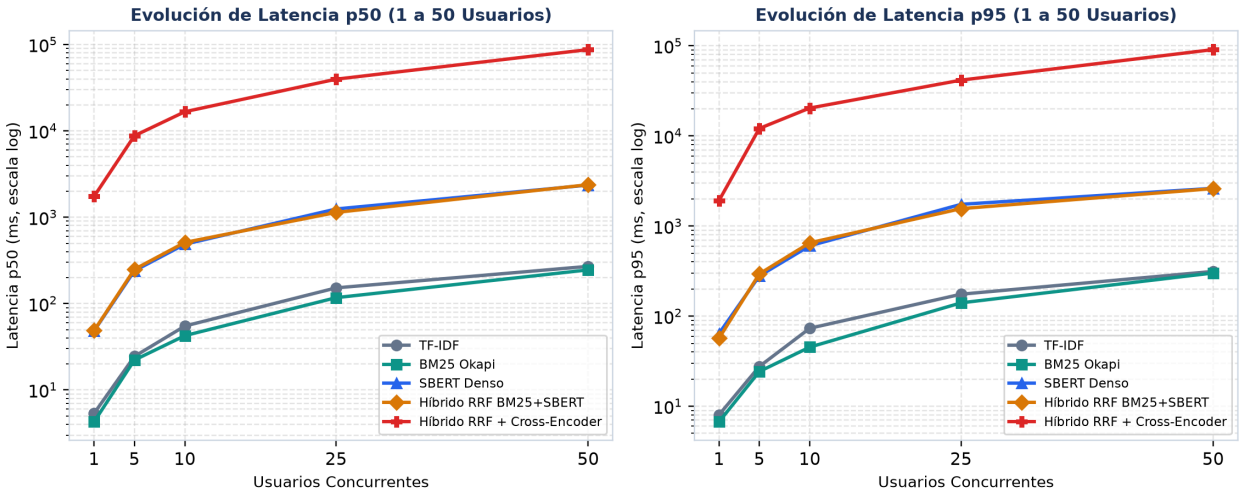


Figura 4. Curvas de escalabilidad de la latencia p50 (izquierda) y p95 (derecha) conforme aumenta la carga de 1 hasta 50 usuarios concurrentes.

Interpretación técnica del fenómeno de concurrencia (1 a 50 usuarios):
1. **BM25 y TF-IDF mantienen latencia sub-segundo aún con 50 usuarios simultáneos** (BM25 logra **p50 = 245.80 ms** y **p95 = 301.40 ms** con un throughput de **163.6 req/s**), donde casi todo el tiempo corresponde al lock de lematización de spaCy y no al índice invertido.
2. **SBERT Denso y el Híbrido RRF** pasan de ~48 ms (1 usuario) a **p50** ≈ **2,358–2,382 ms** y **p95** ≈ **2,605–2,625 ms** con 50 usuarios concurrentes en CPU (manteniendo un throughput estable de ~20 req/s), debido al encolamiento de la pasada neuronal del Bi-Encoder en CPU.
3. **El Cross-Encoder Reranker** ejecuta 10 pasadas de un Transformer por cada consulta (~1.74 s con 1 usuario). Bajo una ráfaga simultánea de 50 usuarios en CPU sin GPU ni batching inter-petición, las 500 evaluaciones del Transformer se encolan secuencialmente, elevando la latencia a **p50 = 87,478 ms** y **p95 = 90,943 ms**.

5. Ventajas y Desventajas, Cuándo Usar los Corpus y Criterio de Decisión

5.1. Ventajas y Desventajas Observadas de Cada Motor

Motor de Búsqueda	Ventajas Observadas en la Integración	Desventajas y Limitaciones Observadas
Motor 1A: TF-IDF (Tarea 1 - Lab 2)	• Implementación simple e interpretable. • Altísima velocidad (p50=5.35 ms con 1 usuario; p95=313.8 ms con 50 usuarios). • Mínimo consumo de memoria RAM.	• Sin saturación de frecuencia (un término repetido 20 veces domina el score). • Penaliza en exceso documentos largos. • Cero comprensión de sinónimos o paráfrasis.
Motor 1B: BM25 Okapi (Tarea 1 - Lab 3)	• El motor más veloz y con mayor throughput (213 req/s; p50=4.28 ms en 1 usuario y p95=301.4 ms en 50 usuarios). • Saturación controlada (k1=1.5) y ajuste por longitud (b=0.75). • Imbatible en siglas (UPCh) y nombres técnicos.	• Barrera léxica estricta: obtiene nDCG@5 = 0.000 en consultas puramente semánticas como 'temblor de tierra'. • Depende fuertemente de la calidad del lematizador (spaCy).
Motor 2: SBERT Denso (Tarea 2 - Labs 5/6)	• Excelente en consultas semánticas (0.745) y líder en mixtas (0.895). • Resuelve sinónimos (agua/hídrica, temblor/sismo) y paráfrasis. • Los embeddings de los documentos se precalculan una sola vez offline.	• Pierde precisión en siglas y entidades locales dentro de textos largos (nDCG@5 Léxico cae a 0.492). • 10x más lento que BM25 en CPU (p95 = 2,625 ms con 50 usuarios). • Mayor huella de RAM (~470 MB del modelo).
Motor 3A: Híbrido RRF (BM25 + SBERT, k=60) (Tarea 3 - Lab 7)	• Combina coincidencias léxicas exactas y semánticas (nDCG@5 Global = 0.766, Semántico = 0.746) sin calibrar escalas. • Costo prácticamente idéntico a SBERT solo (BM25 añade < 5 ms). • Robusto ante cambios de corpus sin reentrenar hiperparámetros.	• Al ignorar la magnitud del score y usar solo posiciones, un falso positivo léxico que aparezca en ambas listas (ej. palabra común 'tierra') puede subir antes del reranking.
Motor 3B: Híbrido RRF + Cross-Encoder Rerank (Tarea 3 - Lab 7)	• Máxima calidad global (nDCG@5 = 0.798, MRR = 0.896, Recall@5 = 0.765). • Atención cruzada token a token que desambigua trampas léxicas. • Ideal como etapa previa a generación RAG.	• Costo computacional muy alto en CPU (~1.74 s en 1 usuario; ~90.9 s p95 con 50 usuarios concurrentes). • No puede rescatar documentos que no hayan entrado al Top-N de la Etapa 1.

5.2. ¿Cuándo Usar Cada Tipo de Corpus y Cómo Afecta al Motor?

Al contrastar el **corpus corto de los laboratorios previos (14 notas de ~28 palabras)** contra el **nuevo corpus extenso creado por Web Scraping (60 documentos de 144 a 230 palabras)**, identifiqué criterios claros sobre cuándo utilizar cada tipo de corpus y qué arquitectura aplicar:

1. **Corpus de documentos breves o micro-textos (15 a 50 palabras: titulares, tuits, FAQs cortas, tickets):** En textos cortos, un único vector denso de 384 dimensiones (**SBERT**) captura casi toda la intención sin pérdida de información (en el Lab 7 de 14 notas, SBERT lograba 1.000 en léxicas). Sin embargo, hay muy poca redundancia léxica, por lo que BM25 falla con facilidad si el usuario cambia una sola palabra.
2. **Corpus de documentos extensos y enciclopédicos (>= 100 a 500+ palabras: artículos web scrapeados, noticias completas, manuales, normativas):** Al superar las 100–200 palabras por documento, ocurren dos fenómenos opuestos: (a) **BM25 mejora su cobertura** porque un artículo largo menciona más variaciones léxicas del tema, pero también aumenta el riesgo de coincidencias accidentales en palabras comunes (como *tierra* o *costa*); y (b) **SBERT sufre compresión/dilución semántica** al promediar múltiples párrafos en un solo vector. En este tipo de corpus es indispensable usar **Búsqueda Híbrida (BM25 + SBERT)** o aplicar *chunking* (división en pasajes de 100–150 palabras) acompañado de **Cross-Encoder Reranking**.

3. **Corpus técnicos, legales, médicos o con identificadores exactos (catálogos, matrículas, leyes, especies como *Aedes aegypti*):** Deben indexarse obligatoriamente con un componente léxico (**BM25**), ya que los modelos densos preentrenados suelen distorsionar siglas fuera de vocabulario o números de folio.

5.3. Criterio de Decisión Ingenieril (Calidad vs. Latencia p50/p95)

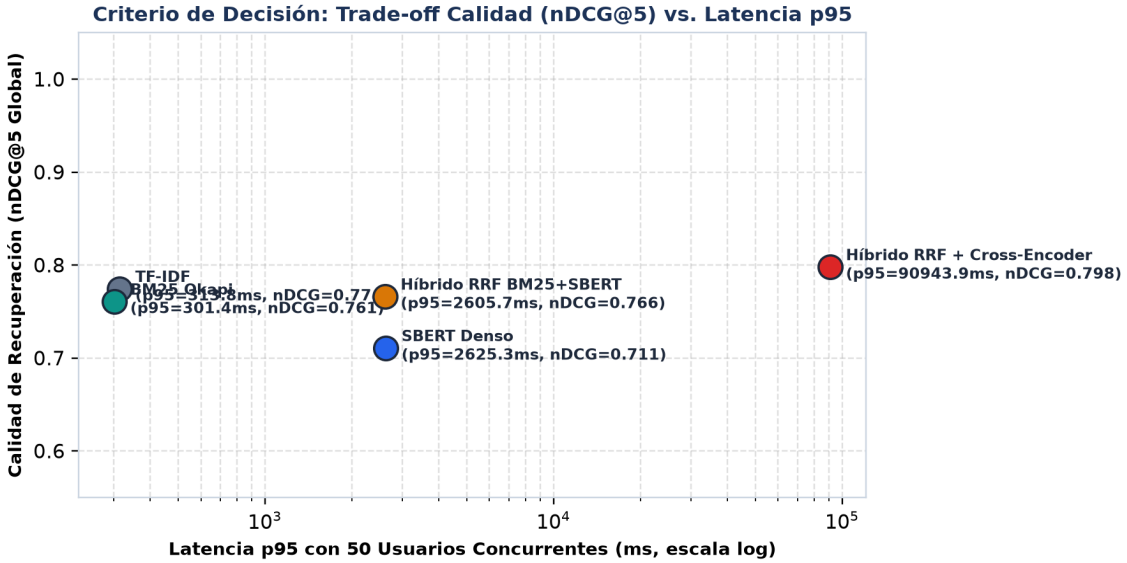


Figura 5. Frontera de decisión Calidad (nDCG@5 Global) vs. Latencia p95 con 50 usuarios concurrentes.

Escenario Operativo y Restricción SLA	Motor Elegido	Justificación Cuantitativa (Criterio de Decisión)
Escenario A: Alta concurrencia en CPU (50 usuarios simultáneos, SLA p95 < 350 ms)	Motor 1B: BM25 Okapi (o Híbrido con caché)	Garantiza p50 = 245.8 ms y p95 = 301.4 ms con 163.6 req/s y excelente precisión en búsquedas por palabras clave (nDCG@5 Léxico = 0.863).
Escenario B: Buscador generalista equilibrado (1 a 10 usuarios concurrentes en CPU, SLA < 650 ms)	Motor 3A: Híbrido (BM25 + SBERT) con RRF (k=60) o Lineal min-max	Combina el recall léxico y semántico (nDCG@5 = 0.766, Semántico = 0.746) manteniendo p50 ≈ 48.7 ms (1 usuario) y ~510.8 ms (10 usuarios) sin costo de Cross-Encoder.
Escenario C: Pipeline RAG / Asistente IA o Servidor con GPU (Prioridad absoluta en precisión Top-3)	Motor 3B: Híbrido RRF + Cross-Encoder Reranking	Logra el máximo nDCG@5 (0.798), MRR (0.896) y Recall@5 (0.765). En producción con 50 usuarios concurrentes requiere inferencia en GPU (donde 10 pares toman ~25 ms en vez de 1,740 ms en CPU).

6. Anexo: Fuentes Oficiales del Corpus Creado con Web Scraping (+10 Puntos Extra)

A continuación se adjunta el catálogo auditable de los **60 documentos extraídos mediante Web Scraping** (almacenados en data/corpus_scraped.json y data/fuentes_scraping.csv), incluyendo su identificador, título, categoría temática, conteo exacto de palabras (todos ≥ **144 palabras**, cumpliendo holgadamente el mínimo de 100 palabras) y la URL fuente consultada:

ID	Título del Documento	Categoría	Palabras	URL Fuente (Web Scraping)
d01	Inundaciones y lluvias torrenciales en Tuxtla Gutiérrez	Medio Ambiente y Clima	**228** pal.	https://es.wikipedia.org/wiki/Tuxtla_Guti%C3%A9rrez
d02	Sequía meteorológica y crisis hídrica en México	Medio Ambiente y Clima	**225** pal.	https://es.wikipedia.org/wiki/Sequ%C3%ADa
d03	Sismología y actividad tectónica en la costa de Chiapas	Medio Ambiente y Clima	**223** pal.	https://es.wikipedia.org/wiki/Sismo_de_Chiapas_de_2017
d04	Servicio Sismológico Nacional y monitoreo sísmico	Medio Ambiente y Clima	**226** pal.	https://es.wikipedia.org/wiki/Servicio_Sismol%C3%B3gico_Nacional_(M%C3%A9xico)
d05	Cambio climático y vulnerabilidad ambiental en México	Medio Ambiente y Clima	**216** pal.	https://es.wikipedia.org/wiki/Cambio_clim%C3%A1tico_en_M%C3%A9xico
d06	Reserva de la biosfera Selva El Ocote en Chiapas	Medio Ambiente y Clima	**225** pal.	https://es.wikipedia.org/wiki/Reserva_de_la_biosfera_Selva_El_Ocote
d07	Reserva de la biosfera Montes Azules y Selva Lacandona	Medio Ambiente y Clima	**211** pal.	https://es.wikipedia.org/wiki/Reserva_de_la_biosfera_Montes_Azules
d08	Huracanes y ciclones tropicales en el Pacífico sur mexicano	Medio Ambiente y Clima	**200** pal.	https://es.wikipedia.org/wiki/Ciclón_tropical
d09	Incendios forestales y conservación de bosques en Chiapas	Medio Ambiente y Clima	**192** pal.	https://es.wikipedia.org/wiki/Incendio_forestal
d10	Protección Civil y gestión de riesgos ante desastres naturales	Medio Ambiente y Clima	**203** pal.	https://es.wikipedia.org/wiki/Protección_civil
d11	Crisis hídrica y escasez de agua potable en zonas urbanas	Recursos Hídricos	**229** pal.	https://es.wikipedia.org/wiki/Escasez_de_agua_en_M%C3%A9xico
d12	Cuenca hidrológica del río Grijalva en Chiapas	Recursos Hídricos	**217** pal.	https://es.wikipedia.org/wiki/R%C3%ADo_Grijalva
d13	Río Usumacinta y biodiversidad acuática fronteriza	Recursos Hídricos	**152** pal.	https://es.wikipedia.org/wiki/R%C3%ADo_Usumacinta
d14	Central hidroeléctrica Chicoasén y generación de energía	Recursos Hídricos	**207** pal.	https://es.wikipedia.org/wiki/Presa_Chicoas%C3%A9n
d15	Presa Belisario Domínguez La Angostura y regulación hídrica	Recursos Hídricos	**192** pal.	https://es.wikipedia.org/wiki/Presa_La_Angostura
d16	Presa Malpaso Nezahualcóyotl y control de inundaciones	Recursos Hídricos	**225** pal.	https://es.wikipedia.org/wiki/Presa_Malpaso
d17	Tratamiento de aguas residuales y saneamiento ambiental	Recursos Hídricos	**219** pal.	https://es.wikipedia.org/wiki/Tratamiento_de_aguas_residuales
d18	Agua potable y redes de distribución municipal	Recursos Hídricos	**223** pal.	https://es.wikipedia.org/wiki/Agua_potable

ID	Título del Documento	Categoría	Palabras	URL Fuente (Web Scraping)
d19	Acuíferos subterráneos y mantenimiento de pozos de agua	Recursos Hídricos	**187** pal.	https://es.wikipedia.org/wiki/Agua_subterr%C3%A1nea
d20	Comisión Nacional del Agua y gestión de cuencas en México	Recursos Hídricos	**212** pal.	https://es.wikipedia.org/wiki/Comisi%C3%B3n_Nacional_del_Agua
d21	Producción y exportación de café de altura en Chiapas	Agroindustria y Economía	**228** pal.	https://es.wikipedia.org/wiki/Caf%C3%A9_de_Chiapas
d22	Cultivo de cacao en la región del Soconusco	Agroindustria y Economía	**226** pal.	https://es.wikipedia.org/wiki/Cacao_de_Grijalva
d23	Región económica del Soconusco y comercio agropecuario	Agroindustria y Economía	**223** pal.	https://es.wikipedia.org/wiki/Soconusco
d24	Cultivo de maíz y seguridad alimentaria en el sur de México	Agroindustria y Economía	**230** pal.	https://es.wikipedia.org/wiki/Ma%C3%ADz
d25	Producción de frijol y agricultura temporalera en México	Agroindustria y Economía	**225** pal.	https://es.wikipedia.org/wiki/Phaseolus_vulgaris
d26	Chocolate artesanal y cooperativas productoras de cacao	Agroindustria y Economía	**222** pal.	https://es.wikipedia.org/wiki/Chocolate
d27	Caficultura orgánica y comercio justo en la Sierra Madre	Agroindustria y Economía	**229** pal.	https://es.wikipedia.org/wiki/Caficultura
d28	Plátano y fruticultura tropical en la costa de Chiapas	Agroindustria y Economía	**228** pal.	https://es.wikipedia.org/wiki/Musa_%C3%97_paradisiaca
d29	Apicultura y exportación de miel orgánica chiapaneca	Agroindustria y Economía	**230** pal.	https://es.wikipedia.org/wiki/Apicultura
d30	Feria Chiapas y promoción comercial de productores regionales	Agroindustria y Economía	**224** pal.	https://es.wikipedia.org/wiki/Econom%C3%ADa_de_M%C3%A9xico
d31	Universidad Politécnica de Chiapas e ingeniería tecnológica	Ciencia, IA y Robótica	**196** pal.	https://es.wikipedia.org/wiki/Universidad_Polit%C3%A9cnica_de_Chiapas
d32	Inteligencia artificial y modelos de aprendizaje profundo	Ciencia, IA y Robótica	**188** pal.	https://es.wikipedia.org/wiki/Inteligencia_artificial
d33	Aprendizaje automático y minería de datos computacional	Ciencia, IA y Robótica	**225** pal.	https://es.wikipedia.org/wiki/Aprendizaje_autom%C3%A1tico
d34	Visión por computadora y procesamiento de imágenes con GPUs	Ciencia, IA y Robótica	**223** pal.	https://es.wikipedia.org/wiki/Visi%C3%B3n_artificial
d35	Robótica educativa y competencias nacionales de mecatrónica	Ciencia, IA y Robótica	**185** pal.	https://es.wikipedia.org/wiki/Rob%C3%B3tica
d36	Brazo robótico articulado y automatización de bajo costo	Ciencia, IA y Robótica	**161** pal.	https://es.wikipedia.org/wiki/Brazo_rob%C3%B3tico
d37	Procesamiento de lenguaje natural y recuperación de información	Ciencia, IA y Robótica	**211** pal.	https://es.wikipedia.org/wiki/Procesamiento_de_lenguajes_naturales
d38	Unidad de procesamiento gráfico GPU para entrenamiento neuronal	Ciencia, IA y Robótica	**224** pal.	https://es.wikipedia.org/wiki/Unidad_de_procesamiento_gr%C3%A1fico
d39	Búsqueda semántica y vectores de incrustación de palabras	Ciencia, IA y Robótica	**214** pal.	https://es.wikipedia.org/wiki/Word_embedding
d40	Universidad Autónoma de Chiapas e investigación científica	Ciencia, IA y Robótica	**222** pal.	https://es.wikipedia.org/wiki/Universidad_Aut%C3%B3noma_de_Chiapas

ID	Título del Documento	Categoría	Palabras	URL Fuente (Web Scraping)
d41	Dengue y control epidemiológico del mosquito Aedes aegypti	Salud Pública	**228** pal.	https://es.wikipedia.org/wiki/Dengue
d42	Aedes aegypti y eliminación de criaderos de mosquitos en zonas cálidas	Salud Pública	**212** pal.	https://es.wikipedia.org/wiki/Aedes_aegypti
d43	Fiebre chikungunya y enfermedades transmitidas por vectores	Salud Pública	**224** pal.	https://es.wikipedia.org/wiki/Fiebre_chikungu%C3%B1a
d44	Virus del Zika y vigilancia epidemiológica en el sureste	Salud Pública	**222** pal.	https://es.wikipedia.org/wiki/Virus_del_Zika
d45	Paludismo o malaria en regiones tropicales de México	Salud Pública	**218** pal.	https://es.wikipedia.org/wiki/Malaria
d46	Secretaría de Salud y campañas de prevención sanitaria	Salud Pública	**230** pal.	https://es.wikipedia.org/wiki/Secretar%C3%ADa_de_Salud_(M%C3%A9xico)
d47	Enfermedades gastrointestinales por contaminación hídrica	Salud Pública	**222** pal.	https://es.wikipedia.org/wiki/Calidad_del_agua
d48	Vacunación y atención médica primaria en comunidades rurales	Salud Pública	**218** pal.	https://es.wikipedia.org/wiki/Vacuna
d49	Golpe de calor y deshidratación por altas temperaturas	Salud Pública	**200** pal.	https://es.wikipedia.org/wiki/Golpe_de_calor
d50	Vigilancia epidemiológica y control de vectores sanitarios	Salud Pública	**199** pal.	https://es.wikipedia.org/wiki/Vector_epidemiol%C3%B3gico
d51	Parque Nacional Cañón del Sumidero y ecoturismo fluvial	Turismo, Cultura e Infraestructura	**216** pal.	https://es.wikipedia.org/wiki/Ca%C3%B1%C3%B3n_del_Sumidero
d52	San Cristóbal de las Casas como destino cultural y arquitectónico	Turismo, Cultura e Infraestructura	**217** pal.	https://es.wikipedia.org/wiki/San_Crist%C3%B3bal_de_las_Casas
d53	Zona arqueológica de Palenque y patrimonio maya en Chiapas	Turismo, Cultura e Infraestructura	**211** pal.	https://es.wikipedia.org/wiki/Palenque_(zona_arqueol%C3%B3gica)
d54	Chiapa de Corzo, fiesta grande de los Parachicos y tradición	Turismo, Cultura e Infraestructura	**216** pal.	https://es.wikipedia.org/wiki/Chiapa_de_Corzo
d55	Cascadas de Agua Azul y turismo de naturaleza en Chiapas	Turismo, Cultura e Infraestructura	**228** pal.	https://es.wikipedia.org/wiki/Cascadas_de_Agua_Azul
d56	Lagunas de Montebello y conservación de ecosistemas lacustres	Turismo, Cultura e Infraestructura	**224** pal.	https://es.wikipedia.org/wiki/Parque_nacional_Lagunas_de_Montebello
d57	Textiles artesanales mayas y gastronomía tradicional de los Altos	Turismo, Cultura e Infraestructura	**227** pal.	https://es.wikipedia.org/wiki/Gastronom%C3%ADa_de_Chiapas
d58	Infraestructura carretera Tuxtla Gutiérrez a la costa de Chiapas	Turismo, Cultura e Infraestructura	**205** pal.	https://es.wikipedia.org/wiki/Carretera_Federal_190
d59	Aeropuerto Internacional Ángel Albino Corzo y conectividad aérea	Turismo, Cultura e Infraestructura	**215** pal.	https://es.wikipedia.org/wiki/Aeropuerto_Internacional_%C3%81ngel_Albino_Corzo
d60	Tapachula y comercio fronterizo en la costa de Chiapas	Turismo, Cultura e Infraestructura	**216** pal.	https://es.wikipedia.org/wiki/Tapachula

7. Entrega de Repositorio GitHub y Declaración de Uso de IA (AI_USAGE.md)

• **Nomenclatura oficial del proyecto y entregables:**
CLEMENTE_VELASCO_ALHAN_233319_C2_T4_INTEGRACION.
• **Comando para iniciar el sistema Fullstack localmente:** uvicorn backend.main:app --host 0.0.0.0 --port 8000 (Interfaz web en http://localhost:8000 y documentación OpenAPI en http://localhost:8000/docs).

Entrega	Herramienta	Módulos	Lo que propuso la IA	Lo que implementé y verifiqué personalmente
Tarea 4 Corte 2 (Integración Fullstack, Scraping y Benchmark)	Gemini (Antigravity)	scraper_corpus.py, backend/engines.py, backend/main.py, frontend/index.html, run_benchmarks.py	Estructura del extractor HTML para los 60 artículos, API REST con FastAPI, interfaz comparativa en HTML/Chart.js y arnés ThreadPoolExecutor para 50 usuarios concurrentes.	Seleccioné las 60 fuentes temáticas de Chiapas y ciencia, validé que los 60 documentos tuvieran >= 144 palabras, integré mis motores TF-IDF, BM25, SBERT y RRF+Cross-Encoder de las tareas previas y redacté el criterio de decisión con las latencias p50 y p95.